

UNIVERSIDAD AUTÓNOMA DEL PERÚ
Facultad de Ingeniería y Arquitectura
Escuela Profesional de Ingeniería de Sistemas

INFORME FINAL DEL PROYECTO

Sistema de Predicción de Churn para Clientes de una Empresa de Telecomunicaciones B2B utilizando Big Data y Machine Learning

Curso	Big Data (DD283) — Ciclo VIII
Docente	Mg. Rubén Quispe Llaccharimay
Semestre	2026-1
Entregable	Semana 8 — Informe Final
Repositorio	github.com/jlindo-cloud/bigdata-g1-churn-telecom-b2b
Dashboard	v0-churntelco2b2.vercel.app
Video de demostración	drive.google.com/file/d/1SbeNbehBP5sFfGkmTINcg1f9zYW2vYNI/view
Presentación final	canva.com/design/DAHQPktfiLA/nGreNzr4fD-P_MBnThFVHg

Integrantes

Apellidos y Nombres	ORCID
Asto Arotinco, Ana	0000-0002-2195-0764
Flores Condeña, Javier	0000-0003-2800-5084
Lindo Barrientos, Jhonn Viequier	0000-0001-6025-7332
Tito Paredes, Arian	0009-0002-5717-8099
Quispe Poma, Cristian	0009-0008-6566-3741

1. Resumen ejecutivo

El presente informe documenta el desarrollo completo de un sistema de predicción de churn (abandono de clientes) para el segmento corporativo B2B de una empresa de telecomunicaciones, construido a lo largo de ocho semanas mediante tecnologías de Big Data y Machine Learning.

El proyecto integró siete fuentes de datos independientes —información maestra de empresas, servicios contratados, consumo, facturación, tickets de soporte, eventos de red y registro histórico de churn— en un dataset consolidado de **5,000 clientes empresariales** y 30 variables, aplicando una arquitectura **Medallion (Bronze, Silver y Gold)** sobre Apache Spark en Databricks Community Edition.

Sobre ese dataset se entrenó un modelo de clasificación binaria **Gradient Boosted Trees (GBTClassifier)** de Spark MLlib, cuyas predicciones fueron persistidas en MongoDB Atlas y expuestas mediante un backend en FastAPI hacia un dashboard web desarrollado en Next.js y desplegado en Vercel, denominado **Telco AI**.

El modelo alcanzó un desempeño de 100 % en Accuracy, Precision, Recall y F1-Score sobre el conjunto de prueba. Como se analiza en detalle en la **Sección 7**, este resultado no debe interpretarse como evidencia de un modelo excepcional, sino como consecuencia directa de la naturaleza sintética del conjunto de datos empleado, en el que varias variables separan las clases de forma perfecta. El informe documenta este hallazgo de manera transparente y propone las acciones correctivas correspondientes.

Resultados en una mirada

Dimensión	Resultado obtenido
Cientes analizados	5,000 empresas
Variables consolidadas	30 (23 predictivas tras la ingeniería de variables)
Tasa de churn en la base	16.80 % (840 de 5,000 clientes)
Modelo campeón	Gradient Boosted Trees (Spark MLlib)
Conjunto de prueba	958 registros (808 no churn / 150 churn)
Métricas obtenidas	Accuracy, Precision, Recall y F1-Score = 1.00
Producto final	Dashboard web Telco AI operativo en la nube

2. Introducción y planteamiento del problema

2.1 Contexto

Las empresas de telecomunicaciones que atienden clientes corporativos enfrentan de forma permanente el riesgo de pérdida de cartera por factores como deterioro de la calidad del servicio, incidencias recurrentes de red, disminución del consumo, insatisfacción con la atención recibida y ofertas de la competencia. A diferencia del segmento masivo, la pérdida de un solo cliente corporativo tiene un impacto económico considerable, dado que estos clientes suelen mantener múltiples servicios contratados y generar facturación recurrente de alto valor.

2.2 Problema identificado

La organización no dispone de un mecanismo que permita identificar de forma anticipada qué clientes empresariales presentan riesgo de abandonar los servicios contratados. La detección tardía impide ejecutar estrategias de retención efectivas y se traduce en pérdidas económicas asociadas a la cancelación de contratos.

2.3 Pregunta de investigación

Pregunta que orienta el proyecto

¿Es posible predecir con al menos 90 días de anticipación qué clientes corporativos presentan una alta probabilidad de churn, utilizando técnicas de Big Data y Machine Learning?

2.4 Objetivos

Objetivo general

Desarrollar un modelo predictivo basado en Big Data y Machine Learning que permita identificar clientes B2B con riesgo de abandono con una anticipación mínima de 90 días.

Objetivos específicos

- Integrar información proveniente de múltiples fuentes relacionadas con clientes, servicios, consumo, facturación, tickets de soporte e incidencias de red.
- Ejecutar procesos de limpieza, transformación y validación que garanticen la calidad de los datos.
- Analizar los factores que influyen en el churn mediante análisis exploratorio de datos.
- Construir variables predictivas que representen el comportamiento histórico de los clientes.
- Entrenar y evaluar modelos de Machine Learning para la predicción de churn.
- Comparar algoritmos de clasificación y seleccionar el de mejor desempeño.
- Diseñar un dashboard que permita visualizar los clientes en riesgo y apoyar la toma de decisiones.

2.5 Alcance y exclusiones

Incluido en el alcance	Excluido del alcance
Integración de siete fuentes de datos empresariales	Implementación en ambiente productivo
Procesamiento, limpieza y validación de información	Integración con sistemas transaccionales reales
Análisis exploratorio y construcción de variables	Automatización de campañas comerciales
Entrenamiento y evaluación de modelos de clasificación	Procesamiento en tiempo real (streaming)
Generación de indicadores de riesgo y dashboard	Reentrenamiento automático del modelo

3. Metodología

El proyecto se desarrolló siguiendo un enfoque incremental de ocho semanas, en el que cada etapa produjo entregables verificables que alimentaron la siguiente. La metodología se apoyó en el ciclo estándar de un proyecto analítico: comprensión del negocio, comprensión y preparación de los datos, modelado, evaluación y despliegue.

3.1 Plan de trabajo ejecutado

Semana	Etapas	Entregable principal
1	Definición del problema	Problema de negocio, objetivos, alcance y cronograma
2	Diseño de datos	Fuentes documentadas, modelo relacional y diccionario de datos
3	ETL y calidad de datos	Proceso ETL Medallion, informe de calidad, dataset validado
4	Análisis exploratorio	Notebook de EDA, visualizaciones y variables relevantes
5	Ingeniería de variables	Catálogo de features y dataset final para modelado
6	Machine Learning	Modelo entrenado, métricas y selección del modelo campeón
7	Dashboard y visualización	Dashboard Telco AI, capturas e instrucciones de uso
8	Informe final	Documentación integral, resultados y recomendaciones

3.2 Fuentes de datos

Se utilizaron siete conjuntos de datos que representan dimensiones complementarias del comportamiento del cliente empresarial, permitiendo construir una visión integral de cada cuenta:

Fuente	Dimensión del negocio	Aporte al modelo
empresas.csv	Información maestra	Variables demográficas y de segmentación
servicios.csv	Vinculación comercial	Cantidad y tipo de servicios contratados
consumo.csv	Uso del servicio	Consumo promedio, variación y tendencias
facturacion.csv	Comportamiento financiero	Facturación, morosidad y variación de ingresos
tickets.csv	Experiencia del cliente	Volumen de tickets, criticidad y tiempo de resolución
eventos_red.csv	Calidad técnica del servicio	Incidentes, indisponibilidad y frecuencia de fallas
churn.csv	Variable objetivo	Etiqueta de cliente activo (0) o con churn (1)

3.3 Arquitectura del proceso ETL

El procesamiento se implementó sobre **Databricks Community Edition**, empleando Apache Spark y una arquitectura **Medallion** de tres capas, que separa con claridad el dato crudo del dato listo para el negocio:

Capa	Propósito	Notebook
Bronze	Ingesta del dato crudo tal como llega desde los archivos de origen, sin transformación	01_ingestion / 02_bronze
Silver	Limpieza, tipado, eliminación de duplicados, tratamiento de nulos y validación de integridad referencial por company_id	03_silver

Capa	Propósito	Notebook
Gold	Consolidación en una vista única por empresa con variables agregadas listas para análisis y modelado	04_gold

La ventaja de esta separación es la trazabilidad: ante cualquier inconsistencia detectada en el análisis, la capa Bronze conserva el dato original íntegro, lo que permite reprocesar sin pérdida de información.

3.4 Ingeniería de variables

A partir de la capa Gold se construyeron variables agregadas por empresa mediante funciones de agregación de Spark. El resultado fue un conjunto de 23 variables predictivas agrupadas en cinco dimensiones:

Dimensión	Variables generadas
Perfil de la empresa	empleados, sector_index, region_index, segmento_index
Satisfacción	nps, csat
Financiera	facturacion_total, facturacion_promedio, facturacion_maxima, dias_mora_promedio, deuda_total
Consumo y servicios	trafico_total_gb, trafico_promedio_gb, ancho_banda_promedio, pico_maximo_mbps, cantidad_servicios, monto_mensual_promedio, sla_promedio
Soporte y red	cantidad_tickets, tiempo_resolucion_promedio, tickets_escalados, cantidad_eventos, duracion_promedio_eventos

Las variables categóricas (sector, región y segmento) fueron convertidas a representación numérica mediante indexación, requisito para su procesamiento por el algoritmo de clasificación.

3.5 Modelado

Se evaluaron conceptualmente varios algoritmos de clasificación binaria y se implementó Gradient Boosted Trees. La decisión estuvo condicionada por el entorno de ejecución: XGBoost no se encuentra disponible en Databricks Community Edition, por lo que se optó por GBTCClassifier de Spark MLlib, que ofrece un enfoque de boosting equivalente con integración nativa en el ecosistema Spark.

Algoritmo	Estado en el proyecto
Regresión Logística	Evaluado conceptualmente, no implementado
Random Forest	Evaluado conceptualmente, no implementado
Gradient Boosted Trees (GBTCClassifier)	Implementado y seleccionado como modelo campeón
XGBoost	Descartado por indisponibilidad en Databricks Community Edition

Configuración del entrenamiento

Parámetro	Valor
Algoritmo	GBTCClassifier (Spark MLlib)
Número de iteraciones (maxIter)	100
Profundidad máxima (maxDepth)	5
Semilla (seed)	42
Estrategia de partición	Hold-Out mediante randomSplit
Proporción entrenamiento / prueba	80 % / 20 %
Construcción de features	VectorAssembler

El uso de una semilla fija garantiza la reproducibilidad del experimento: cualquier ejecución posterior sobre el mismo dataset producirá idéntica partición y resultados.

4. Resultados del procesamiento de datos

4.1 Dataset consolidado

El proceso ETL produjo un dataset Gold con las siguientes características:

Indicador	Valor
Registros (empresas únicas)	5,000
Columnas totales	30
Variables predictivas utilizadas	23
Variable objetivo	churn (0 = activo, 1 = abandono)
Cientes activos	4,160 (83.20 %)
Cientes con churn	840 (16.80 %)
Formatos de persistencia	Parquet y CSV

La distribución de la variable objetivo presenta un desbalance moderado de aproximadamente 5 a 1. Se trata de una proporción habitual en problemas de churn y no requiere necesariamente técnicas de remuestreo, aunque sí obliga a evaluar el modelo con métricas distintas al Accuracy, ya que un

clasificador que prediga siempre la clase mayoritaria alcanzaría un 83.20 % de aciertos sin aportar valor alguno.

4.2 Hallazgos del análisis exploratorio

El análisis de correlación entre las variables predictivas y la variable objetivo arrojó los siguientes coeficientes, ordenados por magnitud:

Variable	Correlación con churn	Interpretación
duracion_promedio_eventos	0.998	A mayor duración de incidencias, mayor abandono
tiempo_resolucion_promedio	0.992	Demoras en resolver tickets impulsan el churn
dias_mora_promedio	0.955	La morosidad anticipa la salida del cliente
tickets_escalados	0.941	Escalamientos reflejan insatisfacción acumulada
cantidad_eventos	0.905	Frecuencia de fallas técnicas
csat	-0.879	Menor satisfacción, mayor riesgo
cantidad_tickets	0.858	Volumen de incidencias reportadas
nps	-0.825	Menor recomendación, mayor riesgo
trafico_promedio_gb	-0.295	Caída de consumo asociada al abandono

Desde la perspectiva del negocio, la lectura es consistente y accionable: **la calidad técnica del servicio y la experiencia de soporte son los factores dominantes del abandono**, por encima de las variables financieras o de consumo. Las cinco correlaciones más altas corresponden a incidencias de red y atención al cliente, lo que sugiere que las acciones de retención deberían priorizar la mejora operativa antes que los incentivos comerciales.

5. Resultados del modelo predictivo

5.1 Métricas de desempeño

El modelo fue evaluado sobre el conjunto de prueba, compuesto por 958 registros no vistos durante el entrenamiento:

Métrica	Valor obtenido	Qué mide
Accuracy	1.00	Proporción total de predicciones correctas
Precision	1.00	De los clientes marcados como churn, cuántos lo eran realmente
Recall	1.00	De los clientes que abandonaron, cuántos fueron detectados
F1-Score	1.00	Media armónica entre Precision y Recall
ROC-AUC	No calculada	Capacidad discriminatoria del clasificador

5.2 Matriz de confusión

	Predicción: No churn	Predicción: Churn
Real: No churn	808 (VN)	0 (FP)
Real: Churn	0 (FN)	150 (VP)

Verdaderos positivos: 150 · Verdaderos negativos: 808 · Falsos positivos: 0 · Falsos negativos: 0

5.3 Cumplimiento de los indicadores de éxito

Los indicadores definidos en la Semana 1 se contrastan a continuación:

Indicador comprometido	Meta	Resultado	Estado
ROC-AUC	≥ 0.80	No calculada	No verificado
Recall	$\geq 75\%$	100 %	Cumplido (ver Sección 7)
Anticipación de la predicción	90 días	Ventana implementada	Cumplido
Dashboard operativo	Sí	Telco AI desplegado	Cumplido

La ausencia del cálculo de ROC-AUC constituye una brecha respecto de lo comprometido inicialmente. Se recomienda incorporarla, dado que es la métrica que mejor describe la capacidad discriminatoria de un clasificador ante distintos umbrales de decisión y resulta especialmente informativa en escenarios con clases desbalanceadas.

6. Solución tecnológica implementada

6.1 Arquitectura de la solución

La solución integra cinco capas tecnológicas que van desde el dato crudo hasta la interfaz de consumo del área comercial:

Capa	Tecnología	Función
Almacenamiento y procesamiento	Databricks Community Edition, Apache Spark, Delta Lake	Ejecución del ETL Medallion sobre los archivos de origen
Modelado	Spark MLlib (GBClassifier)	Entrenamiento del modelo y generación de predicciones

Capa	Tecnología	Función
Persistencia de resultados	MongoDB Atlas	Colecciones predictions, metrics, confusion_matrix y model_info
Servicios (backend)	FastAPI, Docker, Railway	Exposición de endpoints de autenticación, empresas, dashboard, métricas, predicciones y auditoría
Interfaz (frontend)	Next.js, Vercel	Dashboard Telco AI para consulta del área comercial

6.2 Flujo de datos extremo a extremo

Archivos CSV de origen → Ingesta (Bronze) → Limpieza y validación (Silver) → Consolidación por empresa (Gold) → Análisis exploratorio → Ingeniería de variables → Entrenamiento del modelo → Persistencia de predicciones en MongoDB Atlas → API REST en FastAPI → Dashboard web Telco AI.

6.3 Dashboard Telco AI

El dashboard organiza la información en seis secciones orientadas a distintos perfiles de usuario:

Sección	Contenido y propósito
Dashboard	Indicadores ejecutivos: clientes en riesgo, tasa de churn a 90 días, base total, conversiones exitosas, tendencia real frente a predicción, distribución de riesgo y precisión histórica del modelo
Predicciones	Análisis predictivo a 90 días, estado y versión del modelo, y ranking de clientes de alto riesgo con su nivel de confianza
Empresas	Cartera completa con buscador, filtros por nivel de riesgo, facturación anual y tendencia del riesgo por cliente
Reportes	Generación y descarga de reportes mensuales, trimestrales y de precisión del modelo
Administración	Gestión de usuarios, sincronización de datos, reentrenamiento del modelo y monitoreo del estado del sistema
Configuración	Perfil del usuario, alertas de alto riesgo, reportes semanales y preferencias de visualización

Los siete registros gráficos del dashboard se encuentran en la carpeta docs/semana_07/Capturas_Dashboard del repositorio, junto con el documento de instrucciones de uso dirigido a las áreas comerciales.

7. Análisis crítico de los resultados

Hallazgo principal de la evaluación

Las métricas perfectas obtenidas (100 % en Accuracy, Precision, Recall y F1-Score, con cero falsos positivos y cero falsos negativos) no reflejan la calidad del modelo, sino la estructura del conjunto de datos utilizado. El análisis del dataset Gold revela que **siete variables predictivas separan las clases de forma perfecta, sin ningún solapamiento entre clientes con churn y sin churn.**

7.1 Evidencia de la separabilidad perfecta

Al examinar los rangos de valores que toma cada variable en cada clase, se observa que no existe intersección alguna entre ambos grupos:

Variable	Rango en clientes sin churn	Rango en clientes con churn	Solapamiento
duracion_promedio_eventos	19.19 – 41.47	217.57 – 295.16	Ninguno
tiempo_resolucion_promedio	8.20 – 39.20	104.80 – 156.03	Ninguno
dias_mora_promedio	2.38 – 6.71	11.42 – 59.21	Ninguno
tickets_escalados	0 – 5	14 – 66	Ninguno
csat	3.50 – 5.00	1.00 – 3.00	Ninguno
nps	50 – 99	0 – 39	Ninguno
risk_score	0.01 – 59.94	70.01 – 99.99	Ninguno

La consecuencia es directa y verificable: una regla trivial de un solo umbral, sin ningún algoritmo de aprendizaje, alcanza el mismo 100 % de exactitud. Por ejemplo, clasificar como churn a todo cliente cuya duración promedio de eventos supere 129.52 minutos produce una exactitud del 100 % sobre los 5,000 registros. Si un umbral manual iguala el desempeño de un modelo de boosting con 100 iteraciones, el mérito no está en el modelo.

7.2 Causa e interpretación

El conjunto de datos empleado es **sintético**, generado para fines académicos a partir de reglas deterministas: los valores de las variables de soporte, red y satisfacción fueron asignados en función de la etiqueta de churn, y no al revés. Esto explica tanto las correlaciones extraordinariamente altas observadas en el EDA (0.998, 0.992, 0.955) como el desempeño perfecto del clasificador.

La variable **risk_score** merece una mención aparte: presenta separación perfecta con un salto abrupto entre 59.94 y 70.01, lo que indica que fue derivada de la propia etiqueta. Su inclusión entre las variables predictivas constituiría un caso claro de fuga de información (*data leakage*). Aunque la documentación de la Semana 6 no la lista entre las variables de entrada del modelo, se recomienda verificar explícitamente su exclusión en el notebook de entrenamiento.

7.3 Implicancias

Reconocer esta limitación no invalida el trabajo realizado. El proyecto cumplió íntegramente su propósito formativo y técnico: se construyó un pipeline completo, funcional y reproducible que abarca desde la ingesta de datos crudos hasta un dashboard operativo en la nube. Ese pipeline es el activo real del proyecto y funcionaría igual con datos reales.

Lo que no puede afirmarse es que el modelo alcance un 100 % de exactitud con datos productivos. En un escenario real, un modelo de churn bien construido suele situarse en rangos de ROC-AUC entre 0.75 y

0.90; valores superiores al 0.95 son motivo de sospecha de fuga de información antes que de celebración.

Lección metodológica

Un resultado perfecto en un problema de negocio complejo debe tratarse siempre como una señal de alerta y no como un logro. La verificación de solapamiento entre clases y la revisión de correlaciones extremas con la variable objetivo deberían formar parte del protocolo estándar de validación antes de dar por concluido cualquier modelo.

8. Conclusiones

8.1 Sobre el objetivo general

Se desarrolló un sistema completo de predicción de churn para clientes B2B que integra procesamiento distribuido, modelado predictivo y visualización, cumpliendo el objetivo general planteado. La solución identifica clientes en riesgo con la ventana de anticipación de 90 días definida en el alcance.

8.2 Sobre el proceso de datos

- La arquitectura Medallion demostró ser adecuada para el problema: la separación en capas Bronze, Silver y Gold permitió aislar el dato crudo del dato analítico y mantener trazabilidad en todo el proceso.
- La integración de siete fuentes heterogéneas en una vista única por empresa validó la hipótesis de que el churn corporativo requiere una visión integral del cliente, y no el análisis aislado de una sola dimensión.
- El uso de Apache Spark permitió procesar el volumen consolidado de forma distribuida con un pipeline que escalaría sin cambios ante un aumento significativo de registros.

8.3 Sobre los hallazgos analíticos

- Los factores más asociados al abandono corresponden a la calidad técnica del servicio y a la experiencia de soporte —duración de incidencias, tiempo de resolución y escalamientos— por encima de las variables financieras y de consumo.
- Los indicadores de satisfacción (NPS y CSAT) mostraron correlación negativa fuerte con el churn, confirmando su valor como señales tempranas de riesgo.
- La tasa de churn observada del 16.80 % representa un desbalance moderado que exige evaluar el modelo con métricas más informativas que el Accuracy.

8.4 Sobre el modelo

- El algoritmo Gradient Boosted Trees resultó apropiado para el problema por su capacidad de manejar variables numéricas y categóricas y su integración nativa con Spark MLlib.
- Las métricas perfectas obtenidas se explican por la naturaleza sintética del dataset y no por el desempeño del algoritmo; el modelo no ha sido validado en condiciones realistas.
- La omisión del cálculo de ROC-AUC dejó sin verificar uno de los indicadores de éxito comprometidos en la definición del proyecto.

8.5 Sobre la solución tecnológica

- La integración entre Databricks, MongoDB Atlas, FastAPI y Next.js demostró que es viable construir una cadena completa desde el procesamiento analítico hasta una interfaz de negocio utilizando exclusivamente herramientas gratuitas o de capa libre.
- El dashboard Telco AI traduce la salida técnica del modelo en información accionable, organizada por perfil de usuario y con niveles de riesgo interpretables por personal no técnico.

9. Recomendaciones

9.1 Prioridad alta — validez del modelo

Recomendación	Justificación
Validar el modelo con datos reales o con un dataset sintético que incorpore ruido y solapamiento entre clases	Es la única forma de conocer el desempeño verdadero del clasificador; los resultados actuales no son extrapolables
Calcular e informar ROC-AUC y la curva Precision-Recall	Cierra la brecha con el indicador de éxito comprometido y describe el comportamiento del modelo ante distintos umbrales
Auditar el conjunto de variables de entrada y excluir explícitamente risk_score	Previene fuga de información desde variables derivadas de la etiqueta objetivo
Incorporar validación cruzada (k-fold) en lugar de una única partición Hold-Out	Reduce la dependencia del resultado respecto de una partición particular y ofrece una estimación más estable

9.2 Prioridad media — robustez técnica

- Implementar autenticación real con control de acceso por rol en el dashboard, sustituyendo el modo de demostración actual.
- Automatizar la actualización de predicciones mediante un proceso programado, evitando la sincronización manual.
- Registrar el versionado de modelos y su historial de métricas para detectar degradación en el tiempo.
- Establecer pruebas automatizadas de calidad de datos sobre la capa Silver, con umbrales de nulos, duplicados e integridad referencial.

9.3 Prioridad media — aprovechamiento del negocio

- Priorizar la gestión de retención cruzando el nivel de riesgo con la facturación anual del cliente, de modo que el esfuerzo comercial se concentre donde el ingreso en juego es mayor.
- Actuar sobre las causas identificadas en el análisis: dado que las variables dominantes son operativas, las acciones de mayor impacto son reducir la duración de incidencias y los tiempos de resolución, más que ofrecer descuentos.
- Definir un protocolo de intervención por nivel de riesgo, asignando responsables y plazos de contacto diferenciados.
- Medir sistemáticamente la efectividad de las campañas mediante el indicador de conversiones exitosas ya presente en el dashboard.

9.4 Trabajo futuro

- Incorporar variables temporales que capturen la tendencia del comportamiento (variación del consumo o de la facturación en los últimos tres y seis meses) en lugar de únicamente valores agregados.
- Evaluar técnicas de interpretabilidad como SHAP para explicar las predicciones individuales, requisito frecuente para la adopción del modelo por parte de las áreas comerciales.
- Explorar el procesamiento en streaming para detectar cambios de comportamiento en ventanas más cortas.
- Ampliar el alcance hacia un modelo de estimación del valor en riesgo, que combine la probabilidad de abandono con el ingreso asociado a cada cliente.

10. Anexos

10.1 Estructura del repositorio

Ruta	Contenido
data/raw/	Siete archivos CSV de origen
data/processed/	Dataset Gold consolidado en formatos Parquet y CSV
notebooks/Semana02-Ingesta/	01_ingestion.ipynb
notebooks/Semana03-ETL/	02_bronze.ipynb, 03_silver.ipynb, 04_gold.ipynb
notebooks/Semana04-EDA/	05_eda.ipynb
notebooks/Semana05-Feature/	feature_engineering.ipynb
notebooks/Semana06-ML/	07_model_training.ipynb
src/churn_backend/	API REST en FastAPI con routers de autenticación, empresas, dashboard, métricas, predicciones y auditoría
src/churntelecomb2b/	Aplicación web Next.js del dashboard Telco AI
docs/semana_01 ... semana_08/	Documentación e informes de cada etapa, con evidencias gráficas

10.2 Documentos de respaldo por etapa

Etapas	Documentos
Semana 1	problema_negocio.md, objetivos.md, alcance.md, cronograma.md
Semana 2	fuentes_datos.md, diccionario_datos.xlsx, Modelo_Relacional.png
Semana 3	Documento_del_proceso_ETL.md, Informe_de_calidad_de_datos.md, Dataset_procesado_y_validado.md
Semana 4	Informe_Analisis_Exploratorio_de_Datos(EDA).md y evidencias gráficas
Semana 5	feature_engineering.md, dataset_final.md, catalogo_features.xlsx
Semana 6	Machine Learning.md, resultados_modelo.md, metricas_modelo.xlsx
Semana 7	Instrucciones_Uso_Dashboard_TelcoAI.md y siete capturas del dashboard
Semana 8	informe_final.pdf, conclusiones.md, recomendaciones.md, presentacion_final.pptx

10.3 Entregables de la Semana 8

Entregable	Archivo / Enlace
Informe final (PDF)	docs/semana_08/informe_final.pdf
Informe final (Markdown)	docs/semana_08/informe_final.md
Conclusiones	docs/semana_08/conclusiones.md
Recomendaciones	docs/semana_08/recomendaciones.md
Presentación final (Canva)	canva.com/design/DAHQPktfLA/nGreNzr4fD-P_MBnThFVHg
Video de demostración del modelo y dashboard	drive.google.com/file/d/1SbeNbehBP5sFfGkmTINcg1f9zYW2vYNi/view

10.4 Glosario

Término	Definición
Churn	Abandono del servicio por parte de un cliente; en el segmento B2B, la no renovación del contrato
Arquitectura Medallion	Patrón de organización de datos en capas Bronze (crudo), Silver (limpio) y Gold (listo para negocio)
Data leakage	Fuga de información desde la variable objetivo hacia las variables predictoras, que produce métricas artificialmente altas
Hold-Out	Estrategia de validación que divide el dataset en una partición de entrenamiento y otra de prueba
GBTCClassifier	Clasificador de árboles potenciados por gradiente de la librería Spark MLlib
Recall	Proporción de clientes que efectivamente abandonaron y fueron correctamente detectados por el modelo
ROC-AUC	Área bajo la curva ROC; mide la capacidad del modelo para discriminar entre clases
NPS / CSAT	Indicadores de recomendación y satisfacción del cliente

Informe Final — Semana 8 · Proyecto de Predicción de Churn B2B · Big Data (DD283) · Universidad Autónoma del Perú · 2026-1